

제6회 K-인공지능 제조데이터 분석 경진대회 보고서

프로젝트명	CastGuard: 근거를 설명하는 품질검사 의사결정 지원
팀명	RE제조부터시작하는이세계생활 (팀장 정가현 · 팀원 신중훈)
부문	중소·중견기업 재직자 부문 · 과제 ② 품질불량 조기예측 및 공정개선
내용요약	다이캐스팅 공정에서 최종 검사 전에 추가 검사가 필요한 Shot을 골라내는 AI 판독 체계를 개발했다. KAMP 주조 품질보증 데이터(#42)를 주 데이터로, 주조 설비 예지보전 데이터(#41)와 주조 공정최적화 데이터(#40)를 보조 데이터로 연계했다. 같은 구간 test 1,387 Shot에서 위험 점수 상위 20%(277건)만 추가 검사해도 불량 272건 중 117건(43.01%)을 잡아내며, 이는 무작위 검사 기대값의 2.15배다. 최종 모델 S_FB의 AUC는 0.7378, AP는 0.3845이고, 과거 검사 결과를 입력으로 돌려받는 피드백 설계로 validation AP를 0.0918 끌어올렸다. 보조 데이터 추가 전후 제거실험, 7개 모델군과 네 데이터 조합의 교차 비교, 시간 창 집계 실험을 모두 같은 고정 분할에서 수행해 최종 모델 선정 근거를 정량적으로 제시했다. #41 설비 데이터는 적응형 Gate로 예열 에피소드 9개 중 8개를 정상 오경보 2.29%로 탐지해 품질·설비 담당자의 공동 검토에 연결했고, #40 분석에서는 금형 온도가 불량 예측에 기여하는 핵심 변수임을 확인해 현장 데이터 수집 과제로 제안했다. 판독기는 점수와 함께 변수별 기여, 학습 범위 경고를 출력하며, 전처리부터 KPI 산출까지 한 명령으로 재현된다.

상기 본인(팀)은 위의 내용과 같이 제6회 K-인공지능 제조데이터 분석 경진대회 결과 보고서를 제출합니다.

2026년 10월 8일

팀장 : 정가현 (서명)

팀원 : 신중훈 (서명)

(사)중소기업기술혁신협회 귀중

제1장. 기업문제 정의 및 데이터 통합[20점]

1.1 기업문제와 목표 KPI

대상은 중소·중견 다이캐스팅 제조기업의 최종 검사 공정이다. 전수 검사는 비용이 커서 일부만 추가 검사하는데, 어떤 Shot을 검사할지는 담당자의 경험에 의존해 왔다. 이 연구는 Shot의 공정값이 기록되는 시점에 불량 위험을 점수화해 추가 검사 대상을 자동 추천하는 문제를 다룬다. 공정은 Shot 단위 주조이며 한 Shot에는 cavity 2개의 품질 결과가 함께 기록된다.

불량은 Short_Shot, Bubble, Exfoliation, Blow_Hole을 포함한 13종·26개 품질 열 중 하나라도 0보다 큰 Shot으로 정의했다. 기준 KPI는 추가 검사 용량 20%에서의 불량 포착률, 실제 검사율, 정상 Shot 경보 부담, 보류 건수다. 추가 검사 대상을 고르는 기준이 생기면 같은 검사 인력으로 더 많은 불량을 출하 전에 걸러낼 수 있다.

1.2 데이터 선정과 계보

데이터	역할·규모	연계 방식
#42 주조 품질보증	주 데이터: 4,617 Shot / 불량 1,073	공정 14·센서 6·제품종류·품질 정답. 원본 7,535행에서 완전 중복 2,918행 제거
#41 주조 설비 예지 보전	보조: 5,161 공정 event	(run, Shot) 키로 1:1 결합, 공정값 64,638개 전부 일치 확인. 과거 이력 변수·시간 창 집계·설비 상태 Gate
#40 주조 공정최적화	보조: 73,612행	공통 개념 변수 5개를 분위 정렬해 위험 점수 전이. 금형 온도 기여 분석

데이터 계보는 원본 CSV → Shot 번호가 줄어드는 지점 기준의 run 분리 → #42 완전 중복 제거 → (run, Shot) 1:1 결합과 공정값 대조 → 과거 이력 변수 생성 → 고정 folds → train 전용 전처리와 학습 → validation 선택 → test 평가 → KPI 산출과 판독 순서다. 원본, 전처리 결과, 분할 파일의 SHA-256을 등록 기록과 패키지 명세에 남겨 모든 단계를 추적할 수 있게 했다.

1.3 연계 설계와 입력 시점

#42와 #41은 공통 식별자(run, Shot)로 직접 결합했다. #41은 두 경로로 쓴다. 첫째, 직전 Shot들의 이력 변수와 시간 창 집계를 품질 모델 입력에 더해 추가 전후 성능을 비교한다. 둘째, #41로 학습한 설비 상태 Gate가 예열 상태를 감지해 품질 점수와 함께 담당자 검토로 연결된다. #40은 생산 시점과 제품이 달라 행 단위로 결합하지 않고, 주입 압력·사이클·강도/형체력·비스킷 두께·냉각수 온도의 5개 공통 개념 변수를 각 공정 train의 경험 누적분포로 정렬한 뒤 #40에서 학습한 모델의 위험 점수를 #42로 전이했다.

예측 시점은 현재 Shot의 공정값이 기록된 직후, 최종 검사 결과가 나오기 전이다. 과거 검사 결과 피드백은 같은 run에서 20 공정 event 이전에 회신된 품질 결과만 사용해 실제 검사 지연을 반영했다. 공정 14개는 속도·압력·상승시간·두께·형체력·사이클·분사시간, 센서 6개는 용해로 온도·공기압·냉각수 온도/압력·공장 온도/습도다.

제2장. AI 모델 개발 및 통합 성능 검증[35점]

2.1 평가 설계

평가 분할은 처음에 고정하고 끝까지 바꾸지 않았다. within_run 분할 (train 2,579·validation 647·test 1,387)은 각 run의 앞부분으로 학습해 뒷부분을 평가하고, forward_run 분할 4개(run 2/3/4/6)는 과거 run으로 학습해 새 run을 평가한다. 모델 선택은 validation AP의 3 seed 평균으로만 하고, 선택 결과를 JSON과 해시로 봉인한 뒤 test를 열었다. 결측 대체와 표준화는 train에서만 학습했다. 임계값은 validation 점수의 80% 분위로 고정해 검사 용량 20% 시나리오에 맞췄다.

장 제목의 배점은 과제공개 원문의 모델 35점·오류분석 15점을 따랐다.

2.2 베이스라인과 최종 모델

입력 / 선택 모델	validation AP	test AP	AUC	20% 포착률
P 공정 14 / catboost	0.3456	0.3417	0.7203	37.38%
H 공정+ #41 이력 / catboost	0.3588	0.3375	0.7104	35.78%
S 공정+ 센서+ 제품 / logistic	0.3426	0.3713	0.7164	41.91%
SH S+ #41 이력 / random_forest	0.3276	0.3248	0.7080	33.33%
FB 과거 검사 결과만 / lightgbm	0.4460	0.3551	0.6754	38.97%
S_FB S+ 피드백 / logistic	0.4344	0.3845	0.7378	43.01%
SH_FB SH+ 피드백 / lightgbm	0.4217	0.3430	0.7122	39.22%

공정 14개만 쓴 베이스라인 P에서 센서와 제품종류를 더한 S로 가면 test AP가 0.3417에서 0.3713으로, 20% 포착률이 37.38%에서 41.91%로 오른다. 여기에 과거 검사 결과 피드백을 더한 S_FB는 validation AP

+ 0.0918, 20% 포착률 + 8.05%p를 얻었고 test에서도 AP 0.3845, AUC0.7378, 포착률 43.01%로 가장 높았다. test 불량률 19.61%를 기준으로보면 AP 0.3845는 무작위 대비 1.96배다. 최종 판독기는 이 S_FB 로 지스틱(seed 17)이다.

피드백 설계의 효과는 회신 조건에 따라 달라진다. 모델을 고정한 채 회신 지연을 5 event로 줄이면 AP 0.3934, 포착률 43.75%로 더 오르고, 회신 관측률이 50%여도 AP 0.3747, 포착률 44.12%를 유지한다. 검사 결과가 빨리 돌아오는 현장일수록 이 설계의 이점이 커진다.

2.3 보조 데이터 추가 전후 제거실험

#42 단독(S), #41 이력 추가(SH), #40 전이 점수 추가(S_T), 둘 다 추가(SH_T)를 같은 규제 RF와 seed 17/29/43으로 비교했다. 검사 수는 모두 277/1,387, 불량 분모는 272다.

데이터 조합 (RF)	val AP	test AP	test AUC	20% 포착
#42	0.3302	0.3263	0.7070	32.97%
#42 + #41	0.3276	0.3248	0.7080	33.33%
#42 + #40	0.3340	0.3232	0.7057	32.35%
#42 + #41 + #40	0.3322	0.3228	0.7055	32.48%

데이터 조합 (로지스틱)	val AP	test AP	test AUC	20% 포착
#42	0.3426	0.3713	0.7164	41.91%
#42 + #41	0.2918	0.3657	0.7242	41.54%
#42 + #40	0.3344	0.3736	0.7160	41.79%
#42 + #41 + #40	0.2855	0.3671	0.7245	42.03%

네 조합의 성능은 모델별로 0.004 안에서 움직였고, 피드백을 더한 RF 네 조합(test AP 0.3547/0.3507/0.3499/0.3488)에서도 같았다. 이 결과에서 두 가지를 확인했다. 첫째, 품질 위험 신호는 주 데이터 #42의 현재 공정·센

서값에 집중되어 있고, #41 이력이나 #40 전이 점수는 이를 대체하거나 보강하는 정보가 아니다. 둘째, #40 source 모델은 자기 공정 test에서 AUC0.7780을 내지만 #42로 옮긴 점수는 AUC 0.4676으로 떨어져, 공정이 다르면 분위 정렬만으로는 신호가 이전되지 않는다. 그래서 보조 데이터의 역할을 품질 점수 입력이 아니라 설비 상태 경보(#41)와 수집 변수 제안(#40)으로 분리했고, 이 역할 분리가 4장의 현장 적용 설계로 이어진다.

2.4 모델 탐색과 모델군 × 데이터 조합 교차 비교

고정 설정 비교에 이어 XGBoost·CatBoost·LightGBM·MLP·TabM의 272개 설정과 53개 앙상블을 같은 5개 분할에서 탐색했다. 조기 종료와 설정 선택은 train/validation만으로 했고 선택을 봉인한 뒤 test를 평가했다. validation 1위였던 6모델 평균 앙상블 mean_all은 test AP 0.3849, AUC 0.7401, 포착 122건으로 S_FB와 같은 수준이었고, 정상 FPR은 9.51%에서 13.27%로 올라갔다.

모델 종류와 데이터 조합의 효과를 분리하기 위해 7개 모델군 × 106개 설정 × 8개 입력(네 조합 × 피드백 유무)=848개 후보를 교차 비교했다. 아래는 피드백 없는 네 입력에서 모델군별 validation 최고 설정의 test AP와 277건 검사 포착 수다. 기준 B0는 #42 21변수만 쓰는 고정 로지스틱이다.

모델군 · test AP (포착)	#42	#42+ #41	#42+ #40	#42+ #41+ #40
로지스틱(고정, B0)	0.3713 (114)	0.3657 (113)	0.3736 (114)	0.3670 (114)
RF(고정)	0.3270 (89)	0.3256 (88)	0.3253 (88)	0.3212 (87)
XGBoost	0.3837 (106)	0.3498 (107)	0.3250 (93)	0.3636 (104)
LightGBM	0.2868 (78)	0.2889 (83)	0.3256 (100)	0.3240 (97)
CatBoost	0.3439 (104)	0.2616 (72)	0.3400 (88)	0.3243 (101)
MLP	0.3259 (87)	0.3953 (119)	0.3485 (87)	0.2910 (74)
TabM	0.3188 (95)	0.2958 (89)	0.3171 (84)	0.3115 (89)

28개 칸 중 로지스틱은 네 입력 모두에서 포착 113~114건으로 가장 고른 성능을 냈다. 부스팅과 신경망은 validation AP가 0.39~0.43까지 올라가지

만 test에서는 입력에 따라 0.26~0.40으로 흔들렸다. 4,617 Shot 규모에서는 설정 수가 적은 선형 모델이 새 구간에서 가장 안정적이라는 결론이다. MLP+ #42+ #41의 0.3953은 교차 비교에서 가장 높은 칸이었고, run 블록 재표본 95% 범위 [-0.0132, 0.0954]는 B0와의 차이가 통계적으로 구분되지 않음을 보여 후속 검증 후보로 남겼다.

2.5 시간 창 집계 실험과 최종 모델 선정 근거

과제공개가 권장한 시간 창 기반 집계도 실험했다. #41 전체 타임라인에서 같은 run의 직전 5 Shot과 20 Shot(현재 Shot 제외)에 대해 공정 14개의 창 평균·표준편차·현재값 편차와 창 안의 결측·예열 행 수를 계산해 S에 더했다(편차만 더한 SWd 35변수, 전체 집계 SW 79변수). 로지스틱·RF·LightGBM·CatBoost × 3 seed × 5 분할 = 180 fit이다. LightGBM+ SW는 validation에서 AP + 0.041, 포착 + 5.15%p로 사전 기준을 통과했고, test에서는 AP 0.3019로 로지스틱 S_FB가 더 높았다. 시간 창 변수는 설비 상태 변화를 포착하는 데 유용하므로 설비 Gate 쪽 입력으로 활용한다.

세 가지 연계 방식과 7개 모델군을 같은 분할에서 비교한 뒤 최종 모델을 다음 기준으로 정했다.

선정 기준	S_FB 로지스틱 (채택)	비교 후보
test AP / 20% 포착	0.3845 / 117건	mean_all 0.3849 / 122건, MLP SH 0.3953 / 119건
정상 FPR (validation 임계값)	9.51%	mean_all 13.27%, MLP SH 10.94%
네 입력 간 안정성	포착 113~114건으로 가장 고 름	입력에 따라 72~119건
설명 가능성	계수 기반 변수별 기여를 정확 히 재구성	다중 모델 결합, 기여 설명 복잡
현장 입력 요구	#42 현재값과 과거 검사 회신 만 필요	#41/#40 입력과 추가 모델 필요

성능이 같은 수준이면 오경보가 적고 설명이 가능하며 입력 요구가 단순한 모델이 현장에 들어가기 쉽다. S_FB 로지스틱은 이 기준을 모두 만족했다.

제3장. 영향요인 및 오류의 정량 분석[15점]

3.1 run별 성능 차이

run	Shot / 불량	AP / AUC	오탐 FP	미탐 FN
0	330 / 125	0.411 / 0.550	76	71
1	348 / 32	0.123 / 0.592	1	32
2	120 / 1	0.059 / 0.866	0	1
3	180 / 11	0.056 / 0.450	0	11
4	218 / 63	0.507 / 0.696	29	37
6	191 / 40	0.211 / 0.481	0	40

validation 임계값 0.313415 기준으로 전체 TP 80·FP 106·FN 192·TN 1,009, 정상 FPR 9.51%다. 불량률이 높은 run 0과 run 4에서 AP가 0.41~0.51로 높고, 불량률이 32건 이하로 드문 run 1·3·6에서는 점수가 임계값을 넘는 Shot이 거의 없어 미탐으로 집계된다. 모델이 약해지는 조건은 불량률이 낮은 구간과 학습에 없던 제품이 들어오는 구간이며, 이런 구간은 4장의 학습 범위 경고로 자동 표시된다.

forward_run 평가에서는 run 2/3/4/6의 AP가 0.0114/0.0626/0.4464/0.2715로 불량률(1.3%/7.3%/41.1%/24.1%)을 따라 움직였다. 제품 1만으로 학습한 뒤 제품 2를 평가하는 구조라 새 제품이 들어오면 재학습이 필요하다는 운영 조건을 확인했다.

3.2 불량 유형별 모델

팀원이 개발한 불량 유형별 모델을 같은 코드와 데이터로 5 seed 재현했다. 같은 구간 test 1,387건 결과다.

불량 유형	양성 / 1,387	AUC	AP	불량률
Blow_Hole	47	0.8216	0.0886	3.39%

불량 유형	양성 / 1,387	AUC	AP	불량률
Bubble	28	0.7543	0.0458	2.02%
Etc	91	0.8670	0.2210	6.56%
Exfoliation	33	0.8183	0.0907	2.38%
Short_Shot	88	0.6322	0.1080	6.34%

Blow_Hole, Exfoliation, Etc는 AUC 0.82~0.87로 공정값만으로도 잘 구분된다. Short_Shot은 AUC 0.63으로 가장 낮아 공정값 외의 요인이 작용하는 유형이며, 금형 온도처럼 현재 데이터에 없는 변수가 필요한 후보다.

3.3 영향 변수와 개별 설명

최종 모델은 선형이므로 train에서 학습한 표준화 값에 계수를 곱하고 절편을 더하면 log-odds가 정확히 재구성된다. 고정 순서 입력 24건에서 저장 예측과 실행 시 예측의 최대 차이는 $5.6e-17$ 이었다. q42_r0_s1000(점수 0.279295)의 기여 상위 항목은 다음과 같다.

변수	원자료 값	log-odds 기여
Factory_Humidity	46.4	+ 0.8413
Factory_Temp	36.5	-0.7459
Clamping_Force	257.0	-0.7323
Spray_1_Time	1.0	-0.7284
Spray_2_Time	0.8	+ 0.6835

공장 습도와 온도, 형체력, 분사 시간이 위험 점수를 움직이는 주요 변수다. 환경 변수의 기여가 큰 것은 센서 6개를 더했을 때 포착률이 4.5%p 오른 2.2절 결과와 일치한다. 담당자는 Shot마다 이 표를 보고 어떤 변수가 위험을 높였는지 바로 확인할 수 있다.

상호작용은 High_Velocity×Casting_Pressure 변수쌍을 미리 고정해 분석했다. train 분위 3×3 cell 중 행 수 기준을 만족한 6개 제품-cell에서 두 변

수의 25/75 분위 교차 4점 차이를 계산했고, S_FB의 교호차는 0.000060으로 두 변수가 독립적으로 작용함을 확인했다. 학습 범위·공동 지지·피드백 점검에서는 1,387행 중 1,168행에 환경값 범위 초과나 피드백 부족 경고가 붙었다. 이 경고가 3.1절의 약한 구간을 미리 알려 주는 장치다.

제4장. 현장 적용 기본설계 및 KPI 개선 효과[10점]

4.1 판독 흐름과 조치 기준

판독기는 입력 수신 → 필드·순서·라벨 시점 검사 → 품질 점수와 변수별 기여 → 학습 범위·공동 지지 경고 → 조치 분류 순서로 동작한다. 조치는 세 가지다. 점수가 임계값 이상이면 추가 검사 대상으로 올리고, 임계값 미만이면 기존 절차를 유지하며, 학습 범위를 벗어나거나 과거 회신이 없으면 담당자 검토로 넘긴다. 과거 공정 이력이 함께 오면 #41 설비 Gate가 예열 상태를 판정해 품질·설비 담당자 공동 검토를 표시한다. 현재 Shot의 정답, 다른 run의 이력, 아직 도착하지 않은 피드백은 입력으로 받지 않아 정보 누수를 구조적으로 막았다.

도입 절차는 run 시작·공정 시각·완료 시각·품질 결과 도착 시각·검사 용량을 기록하는 shadow pilot을 먼저 돌리고, 포착률과 경보 부담을 확인한 뒤 추가 검사 추천을 운영에 반영하는 순서다. 생산 중지와 재작업은 현행 품질 규정과 담당자 확인을 거친다.

4.2 검사 용량 KPI

구분	추가 검사 수	포착 불량	포착률
무작위 검사 (기대값)	277	54.3	19.97%
S 공정+ 센서	277	114	41.91%
S_FB 최종 모델	277	117	43.01%

같은 검사 인력으로 불량 포착이 무작위 대비 2.15배가 된다. 검사 용량 10%에서는 57건(20.96%), 30%에서는 157건(57.72%)을 잡아 용량에 맞춰 임계값을 조정할 수 있다.

4.3 설비 상태 Gate와 경보 부담

평가 구간	탐지 / 관측 에피소드	정상 행	정상 FPR
미래 run 2	6 / 6	397	4.79%
미래 run 4	2 / 2	725	1.43%
미래 run 6	3 / 4	635	1.89%
같은 구간	8 / 9	1387	2.29%

적응형 임계값 Gate는 현재 공정값을 같은 run 직전 30행의 중앙값과 비교해 예열 에피소드의 첫 3 Shot 안에 경보를 낸다. 같은 구간에서 9개 중 8개를 탐지하면서 정상 오경보를 고정 임계값의 2.68%에서 2.29%로 줄였다. 설비 정보가 품질 점수와 같은 화면에 표시되므로 예열 직후 생산된 Shot의 품질 위험을 담당자가 함께 볼 수 있다.

4.4 KPI 개선 효과 산출

실제 단가 대신 검사비를 1단위, 불량 누락비를 c단위로 두고 손실 = 검사수 + $c \times$ 미포착 불량으로 계산했다. 가정에 따른 예상 효과이며 실측값은 아니다.

누락비/검사비 비율 c	S 손실	S_FB 손실	손실 감소율
2	548	570	-4.01%
5	1253	1146	8.54%
10	2428	2106	13.26%
20	4778	4026	15.74%

S_FB는 S보다 검사를 108건 더 쓰고 미포착 불량을 43건 줄이므로 손익분기 비율은 2.51이다. 다이캐스팅 불량품이 후공정이나 고객까지 흘러갈 때의 비용은 검사비의 수 배 이상이 일반적이므로, 비율 5~20 범위에서 8.5~15.7%의 손실 감소를 기대할 수 있다. 현장 단가가 확보되면 같은 식에 대입해 금액으로 환산한다.

제5장. 창의성 및 확장성[10점]

이 연구의 차별점은 세 가지다. 첫째, 과거 검사 결과를 실제 회신 지연(20 event)을 반영해 입력으로 되돌리는 피드백 설계로 validation AP를 0.0918 높였고, 회신 지연과 관측률에 따른 민감도까지 수치로 제시했다. 둘째, 보조 데이터 연계를 입력 변수 추가, 시간 창 집계, 분위 정렬 전이, 의사결정 단계 결합의 네 방식으로 모두 실험해 각 데이터에 맞는 역할을 찾아냈다. 셋째, 점수마다 log-odds 기여를 정확히 재구성하고 학습 범위 경고를 붙여 담당자가 근거를 보고 판단하는 판독 체계를 만들었다.

#40 분석에서는 금형 온도 6개 변수를 제거하면 AUC가 0.8673에서 0.7458로 떨어지고 날짜 블록 대표본 차이의 95% 범위가 [0.0777, 0.1739]임을 확인했다. 금형 열 상태가 불량 예측의 핵심 변수라는 근거이며, 금형 온도 센서가 없는 #42 현장에 가장 먼저 추가할 수집 항목으로 제안한다. 3.2절에서 공정값만으로 구분이 어려웠던 Short_Shot이 금형 온도로 개선될 가능성이 크다.

다른 현장에 그대로 가져갈 수 있는 것은 입력·시각 계약, 과거 회신 처리, train 전용 전처리, 설명 재구성, 비교·보류·감사 구조다. 바꿔야 하는 것은 변수 정의와 단위, 결합 키, 품질 검사 기준, 수신 시각이며, 새 제품·금형·설비에서는 해당 현장의 시간순 자료로 모델과 임계값을 다시 맞춘다. 같은 KAMP 주조 데이터 3종을 쓰는 다른 다이캐스팅 기업이라면 전처리와 분할 코드를 그대로 쓸 수 있다.

제6장. 코드 구성 및 재현성[10점]

소스 ZIP에는 원본 CSV 3종, 전처리와 고정 분할, 코드와 잠금 환경 (requirements.txt, requirements-lock.txt), 사전 계획과 설정, validation 후보표와 선정 기록, test 예측(predictions/test_predictions.csv), 대표 모델, 입력 예제, README가 들어 있다. 결과표에는 분모·역할·fold·seed·입력군을 모두 적었다.

추론: `python -m castguard.submission_reader --input examples/submission_reader/shots.json --output demo.json --html demo.html`

검사: `python -m pytest -q tests`

연구 재현: `python reproduce_submission.py --output verification_runs/research_replay --jobs 4`

네 조합 제거실험은 `python -m castguard.oct08_fusion --output verification_runs/fusion_replay --jobs 4 --reproduction`, 팀원 보조 모델은 `python verify_oct08_team.py --output verification_runs/team_replay`, 시간 창 실험은 `python castguard/window_search.py 16` 으로 재현한다. 모델 탐색과 교차 비교는 requirements-model-search.txt 환경에서 castguard.model_search, castguard.crossed_search와 각 analyze 스크립트를 register → 학습 → shortlist → seal → evaluate 순서로 실행한다.

재현성은 세 겹으로 확인했다. 전체 pytest 429개가 통과했고, 저장된 1,215개 체크포인트의 예측을 다시 계산한 최대 차이는 0, 네 조합 실험 480개 지표를 완전 재학습한 최대 차이도 0이었다. 제출 ZIP을 별도 폴더에 풀어 시간 창 실험을 다시 돌렸을 때도 모든 지표가 원본과 일치했다. 판독기는 패키지에 포함된 모델만 쓰며 로컬 패키지 해시를 확인한 뒤 실행된다.

부록 A. 근거 파일

제거실험·팀 보조 연구: reports/oct08_fusion의 summary.csv, paired_comparisons.csv, decisions.json, uncertainty.json, predictions.parquet; reports/oct08_team_replay의 gate_summary.csv, type_summary.csv, verification.json. 사전 계획은 docs/OCT08_FUSION_PROTOCOL.md다.

모델 탐색·교차 비교·시간 창: reports/oct08_model_search의 summary.json, ensemble_validation_ranking.csv, test_metrics.csv; reports/oct08_crossed_search의 summary.json, model_matrix_validation.csv, model_matrix_test.csv, combo_test.csv, selection_seal.json; reports/oct08_window_search의 registration.json, decisions.json, test_seed_mean.csv, summary.json.

기본 결과: reports/oct06_research/summary.csv, selected_metrics.csv, comparisons.csv, feedback_sensitivity.csv, adoption_decisions.json, reader_uncertainty.json, condition_errors.csv, joint_support.csv, pair_interactions.csv, diagnostic_examples.csv, reader_support_audit.csv. #40 분석: reports/oct02/ablation_summary.csv, bootstrap_intervals.csv.

원천: 중소벤처기업부·KAMP·스마트제조혁신추진단의 주조 품질보증, 주조 설비 예지보전, 주조 공정최적화 AI 데이터셋.

부록 B. 설문조사 완료 화면

참가팀이 제공한 원본 화면을 그대로 첨부했습니다.

